

DeepSeek OCR 生产级vLLM本地部署

1. 什么是 DeepSeek OCR?

DeepSeek OCR 是一款两阶段 Transformer 文档 AI，先将页面图像压缩成紧凑的视觉 Token，再以高容量的专家混合语言模型解码。阶段一融合窗口化 SAM 视觉 Transformer、致密 CLIP-Large 编码器与 16× 卷积压缩器；阶段二使用 DeepSeek-3B-MoE 解码器（每个 Token 激活约 5.7 亿参数），以最小损耗重建文本、HTML 与图示标注。


模型训练覆盖 3000 万页真实 PDF 及合成图表、公式与示意图，可保留版式结构、表格、化学式（SMILES）与几何任务。得益于 CLIP 血统，多模态能力完整保留——即使在激进压缩后，字幕与目标定位仍旧准确。

官方文档：[DeepSeek OCR | 下一代文档智能](#)

总结：

- **技术本质突破：**
 - DeepSeek OCR 通过光学二维映射技术，将文本信息转化为视觉图像进行高效处理，而非传统的字符识别路径。
 - 极致压缩能力：能够将一页文档从传统OCR所需的几千个 tokens压缩到仅100 tokens左右，压缩率高达达10倍，同时保持了97%以上的准确率。
- **架构创新：**
 - DeepSeek OCR 采用了两阶段设计：由DeepEncoder（3.8亿参数的一个视觉编码器）和 DeepSeek-3B-MoE（30亿参数语言解码器）组成，其中DeepEncoder是核心创新引擎。
 - 三阶段编码流程：从局部感知(SAM-base)→特征提取→光学2D映射压缩，实现内存可控的高效处理。
- **革命性价值：**
 - DeepSeek OCR 专为大语言模型时代构建，解决了传统OCR在大语言模型应用中的上下文窗口瓶颈问题。
 - 为多模态AI提供了高效的信息压缩范式，让视觉与语言能力真正融合，让AI像人类一样"理解"文档结构和语义，而非简单识别文字。这种创新使DeepSeek OCR成为首个真正为大模型生态设计的OCR系统，实现了从"字符识别"到"文档理解"的范式转变。

视觉处理流程：



SAM-CLIP:

- **预处理单元**: 负责接收图像, 并将其分解为全局视图和图块。
- **主模型**: 协调整个流程, 并与SAM编码器、CLIP编码器和视觉语言投影器进行交互。
- **SAM编码器和CLIP编码器**: 分别用于提取图像的初级视觉特征和富含语义的特征。
- **视觉语言投影器**: 将最终的语义特征转换为语言模型能够理解的格式。

CLIP模型架构的核心思想是构建两个独立的编码器, 一个用于图像, 一个用于文本。它们的目标是将输入的图像和文本映射到**同一个多维特征空间**。在这个空间中, 语义匹配的(图像, 文本)对将具有高度相似的特征向量(即余弦相似度高), 而不匹配的则相反。

2. vLLM本地部署DeepSeek OCR

2.1 创建云服务器

通过聚客AI专属链接注册, 即可获得10元免费算力使用, 租云服务器价格更低。

<https://console.comphare.cn/light-gpu/>

1. 扫码注册并进行实名认证
2. 进入控制台 - 部署实例
3. VSCode 远程连接云服务器

2.2 Conda 环境配置

```
conda create -n deepseek-ocr python=3.12.9 -y
conda activate deepseek-ocr
```

2.3 下载DeepSeek OCR模型

使用 modelscope sdk 下载 DeepSeek OCR 模型

```
pip install modelscope
```

```
# download.py

from modelscope import snapshot_download
model_dir = snapshot_download('deepseek-ai/DeepSeek-OCR', cache_dir="/root/.llms/")
```

2.4 克隆DeepSeek OCR到本地

Github 拉取的是 DeepSeek OCR 推理Demo

```
git clone https://github.com/deepseek-ai/DeepSeek-OCR.git
```

2.5 安装依赖包

```
# 下载 vllm-0.8.5 安装包
wget https://github.com/vllm-project/vllm/releases/download/v0.8.5/vllm-0.8.5+cu118-cp38-abi3-manylinux1_x86_64.whl

pip install torch==2.6.0 torchvision==0.21.0 torchaudio==2.6.0 --index-url https://download.pytorch.org/whl/cu118
pip install vllm-0.8.5+cu118-cp38-abi3-manylinux1_x86_64.whl
pip install -r requirements.txt
pip install flash-attn==2.7.3 --no-build-isolation
```

注意：若出现flash attention 编译了很久都没有结果，跳转下面的链接下载对应的版本到本地，直接安装即可！

```
https://github.com/mjun0812/flash-attention-prebuild-wheels/releases?page=3

# 下载
wget https://github.com/mjun0812/flash-attention-prebuild-wheels/releases/download/v0.0.8/flash_attn-2.7.4.post1+cu118torch2.6-cp312-cp312-linux_x86_64.whl

# 安装
pip install flash_attn-2.7.4.post1+cu118torch2.6-cp312-cp312-linux_x86_64.whl
```

注意：如果你希望 vLLM 和 transformers 代码在同一环境中运行，你无需担心类似以下的安装错误：
vllm 0.8.5+cu118 需要 transformers>=4.51.1

```
ERROR: pip's dependency resolver does not currently take into account all the packages that are installed. This behaviour is the source of the following dependency conflicts.
vllm 0.8.5+cu118 requires tokenizers>=0.21.1, but you have tokenizers 0.20.3 which is incompatible.
vllm 0.8.5+cu118 requires transformers>=4.51.1, but you have transformers 4.46.3 which is incompatible.
```

2.6 vLLM推理部署

- VLLM

注意：修改 DeepSeek-OCR-master/DeepSeek-OCR-vllm/config.py 中的 INPUT_PATH/OUTPUT_PATH 及其他设置

```
MODEL_PATH = '/root/llms/deepseek-ai/DeepSeek-OCR # 本地模型路径
INPUT_PATH = '/root/DeepSeek-OCR/input/1.jpg' # 输入路径，文档类型要和运行的脚本类型对应
OUTPUT_PATH = '/root/DeepSeek-OCR/output' # 输出路径

PROMPT = '<image>\n<|grounding|>Convert the document to markdown.'
# PROMPT = '<image>\nFree OCR.'
# TODO commonly used prompts
# document: <image>\n<|grounding|>Convert the document to markdown.
```

```
# other image: <image>\n<|grounding|>OCR this image.
# without layouts: <image>\nFree OCR.
# figures in document: <image>\nParse the figure.
# general: <image>\nDescribe this image in detail.
# rec: <image>\nLocate <|ref|>xxxx</ref|> in the image.
# '先天下之忧而忧'
# .....
```

1. Image图片解析

```
python run_dpsk_ocr_image.py
```

2. PDF文档解析

```
python run_dpsk_ocr_pdf.py
```

2.7 WebUI 部署

参考: [GitHub - neosun100/DeepSeek-OCR-WebUI: 🤖 Ready-to-use DeepSeek-OCR Web UI | Modern Interface | 7 Recognition Modes | Batch Processing | Real-time Logging | Fully Responsive](#)

3. MinerU

Github: [GitHub - opendatalab/MinerU: Transforms complex documents like PDFs into LLM-ready markdown/JSON for your Agentic workflows.](#)

官方中文文档: [MinerU - MinerU](#)

[MinerU 本地部署保姆级“喂饭”教程 | MinerU小站](#)

4. PaddleOCR

[GitHub - PaddlePaddle/PaddleOCR: Turn any PDF or image document into structured data for your AI. A powerful, lightweight OCR toolkit that bridges the gap between images/PDFs and LLMs. Supports 100+ languages.](#)

5. 作业打卡

☒ DeepSeek OCR 本地部署推理

☐ MinerU 本地部署推理

☐ 使用 `vllm` 加速 VLM 模型推理 `mineru[a11]`

☐ 搭建本地API服务

☐ 搭建 Gradio WebUI 服务

☐ PaddleOCR 本地部署推理